

الجمهورية العربية السورية
وزارة التعليم العالي
كلية الهندسة المعلوماتية — قسم هندسة البرمجيات ونظم المعلومات



مشروع مادة استرجاع المعلومات (Information Retrieval) — 2026

بناء نظام استرجاع معلومات

Building an Information Retrieval System

إعداد الطلاب	مجد جميل لوقا مجد سامر عروس	مصطفى عبد الناصر شرف محمد رياض عمر
إشراف	المهندسة المشرفة: م. مروة الداية	
الميزة الإضافية المحققة	تجميع الوثائق (Documents Clustering)	
مجموعة البيانات	382,545 — Webis-Touché 2020 (BEIR) وثيقة	
لغة التطوير	Python — FastAPI — React	

1. مقدمة ونظرة عامة على المشروع
2. وصف مجموعة البيانات (Dataset)
3. بنية النظام والبنية الموجهة بالخدمات (SOA Architecture)
4. خطوات المشروع: خط المعالجة دون اتصال (Offline Pipeline)
5. الخدمات بالتفصيل (Services)
 - 5.1 خدمة المعالجة المسبقة (Preprocessing)
 - 5.2 خدمة الفهرسة (Indexing)
 - 5.3 خدمة الاسترجاع والتمثيل (Retrieval & Representation)
 - 5.4 خدمة تحسين الاستعلام (Query Refinement)
 - 5.5 خدمة الترتيب والتقييم (Ranking & Evaluation)
 - 5.6 بوابة الـ API وواجهة المستخدم
6. التقييم والنتائج والتحليل
7. الميزة الإضافية: تجميع الوثائق (Clustering)
8. تقسيم العمل بين أعضاء المجموعة
9. التقنيات المستخدمة والمصادر
10. الخلاصة والأعمال المستقبلية

1. مقدمة ونظرة عامة على المشروع

يهدف هذا المشروع إلى بناء نظام استرجاع معلومات (Information Retrieval System) متكامل قادر على البحث واسترداد الوثائق من مجموعة بيانات ضخمة، وإعادة النتائج ذات الصلة باستعلام المستخدم وترتيبها حسب درجة التشابه. يطبق النظام مبادئ استرجاع المعلومات الأساسية بدءاً من المعالجة المسبقة للنصوص، مروراً بتمثيل الوثائق بعدة طرائق (شعاعية وكثيفة وهجينة)، وبناء الفهارس، ومعالجة الاستعلامات وتحسينها، وصولاً إلى مطابقة الاستعلام وترتيب النتائج وتقييم جودة الاسترجاع بالمقاييس المعيارية.

صُمم النظام وفق مفهوم البنية الموجهة بالخدمات (Service-Oriented Architecture – SOA) بحيث قُسم إلى مجموعة من الخدمات (المكونات) المستقلة وظيفياً، كل منها مسؤول عن مهمة محددة وقابل للتطوير والاختبار بشكل منفصل، مع بوابة موحدة (API Gateway) تنسق العمل بينها وتعرضه عبر واجهة REST.

ملاحظة منهجية: اعتمد المشروع — وفق تعديل الأستاذة المشرفة — على مجموعة بيانات واحدة بدل مجموعتين، مع تحقيق ميزة إضافية واحدة هي تجميع الوثائق (Clustering).

الأهداف المحققة

- معالجة مسبقة كاملة للنصوص (تنظيف، تطبيع، تجزئة، إزالة كلمات وقف، تجذير).
- تمثيل الوثائق بأربع طرائق: Word2Vec، SBERT (Embeddings)، BM25، TF-IDF (VSM) إضافة إلى التمثيل الهجين Hybrid (تسلسلي ومتوازي).
- بناء فهرس مقلوب (Inverted Index) فعال يدعم BM25.
- تحسين الاستعلام: تصحيح إملائي، توسيع بالمرادفات، واقتراحات من سجل البحث.
- ترتيب النتائج وتقييم النظام بمقاييس MAP و Recall و P@10 و nDCG.
- واجهة مستخدم حديثة (React) للبحث والتحكم بالنماذج والمعاملات.
- ميزة إضافية: تجميع الوثائق إلى عناقيد موضوعية مع تمثيل بصري ثنائي الأبعاد.

2. وصف مجموعة البيانات (Dataset)

اعتمد المشروع على مجموعة بيانات **Webis-Touché 2020** ضمن مرجعية **BEIR** بالمعزّف `beir/webis-touche2020/v2`، وهي مجموعة مخصّصة لاسترجاع الحجج والمواقف الجدلية (Argument Retrieval) حول قضايا خلافية (التعليم، الصحة، الدين، السياسة، البيئة... إلخ). تتميز هذه المجموعة بأن استعلاماتها أسئلة جدلية حقيقية، ما يجعلها مناسبة لاختبار جودة الاسترجاع الدلالي والكلمي معاً.

الخاصية	القيمة
المعزّف	<code>beir/webis-touche2020/v2</code>
عدد الوثائق	382,545 وثيقة
عدد الاستعلامات (Queries)	50 استعلاماً (استُخدم 49 منها في التقييم)
ملف الحقيقة الأرضية (qrels)	متوفّر — درجات صلة 0 / 1 / 2
بنية الوثيقة	عنوان (title) + نص (text)
طبيعة الاستعلامات	أسئلة جدلية، مثل: "Should teachers get tenure?"

تحقّق المشروع شرط حجم المجموعة (أكثر من 200 ألف وثيقة)، كما أنها تحتوي على بيانات اختبار (queries) وملف qrels اللازم للتقييم، وهي ليست من المجموعات الممنوعة (Antique).

التخزين

تُخزّن الوثائق الأصلية (العنوان والنص) في قاعدة بيانات **MongoDB** (قاعدة `ir_system`، مجموعة `documents`) لاسترجاعها بسرعة وعرض مقتطفات النتائج للمستخدم، بينما تُخزّن البيانات المُعالجة والنماذج والفهارس كملفات على القرص ضمن مجلد `data/`.

3. بنية النظام والبنية الموجهة بالخدمات (SOA)

صُمِّم النظام كـ "نظام موجه بالخدمات (SOA)" حيث قُسمت المسؤوليات إلى وحدات منطقية مستقلة (خدمات)، يتحمّل كل منها مهمة واحدة محددة. تتواصل واجهات المستخدم مع النظام عبر بوابة API موحّدة (FastAPI على المنفذ 8000) تعتمد بروتوكول REST/JSON، فيما تُستدعى الخدمات الداخلية بوصفها وحدات برمجية منظّمة لتحقيق أداءٍ عالٍ وزمن استجابة منخفض، مع فصلٍ واضح للمسؤوليات وقابلية للصيانة والتوسّع.

طبقة العرض — Presentation Layer

Postman

API اختبار الـ

واجهة Streamlit

Demo / نموذج أولي

واجهة الويب React

TypeScript + Vite

▼ REST / JSON ▼

بوابة الواجهة — API Gateway (FastAPI :8000)

منسّق خط البحث (Search Pipeline)

/api/v1/search · /suggestions · /evaluation · /clusters

طبقة الخدمات المنطقية — Business / Services Layer

الاسترجاع

Retrieval

الفهرسة

Indexing

المعالجة المسبقة

Preprocessing

التجميع

Clustering

الترتيب والتقييم

Ranking & Evaluation

تحسين الاستعلام

Query Refinement

طبقة التخزين — Persistence Layer

ملفات النماذج والفهارس

data/models · data/indexes

MongoDB

الوثائق الأصلية: 27017

آلية التواصل بين الخدمات

- الواجهات ← البوابة: عبر REST API (HTTP/JSON).
- البوابة ← الخدمات الداخلية: عبر استدعاءات برمجية مباشرة (in-process) داخل عملية الخادم نفسها، ما يلغي زمن الشبكة بين الخدمات ويبقي الفصل المنطقي للمسؤوليات.

- الخدمات ← التخزين: MongoDB للوثائق، وملفات `.pk1/.npz/.faiss` للنماذج والفهارس.

قرار تصميمي: اعتمد نمط "الموناليث المعياري الموجه بالخدمات (Modular Monolith / SOA)": خدمات منفصلة منطقياً ومنظمة في حزم Python مستقلة قابلة للاختبار، مع بوابة واحدة للنشر تبسّط التشغيل (عملية uvicorn واحدة + حاوية MongoDB). هذا يحقق **Loose Coupling** و **Reusability** و **Maintainability** مع أداء أفضل من الاستدعاءات الشبكية بين الخدمات.

مبادئ التصميم المطبقة

Lazy Loading للنماذج

Maintainability

Reusability

Loose Coupling

Separation of Concerns

Clean Architecture

Streaming لمعالجة الذاكرة

4. خطوات المشروع: خط المعالجة دون اتصال (Offline Pipeline)

قبل تشغيل البحث، يُنفَّذ خط معالجة من عشر خطوات لبناء الفهارس والنماذج وتجهيز قاعدة البيانات. صُمِّمت الخطوات لتكون فعّالة من حيث الذاكرة عبر معالجة البيانات على دفعات (Streaming) كي تتحمّل أكثر من 382 ألف وثيقة.

1 **التنزيل (Download):** تنزيل المجموعة عبر مكتبة `ir_datasets` وحفظ الوثائق والاستعلامات وملف `qrels` في

`data/raw/`.

2 **المعالجة المسبقة (Preprocess):** تطبيع وتجزئة وتجزير كل الوثائق وحفظها كتدفّق على دفعات (20 ألف وثيقة/دفعة) في

`processed_docs.pk1`.

3 **بناء الفهرس المقلوب (Inverted Index):** حساب ترددات الكلمات (TF) وأطوال الوثائق وتردد الوثيقة (DF) وإحصاءات

المتن اللازمة لـ BM25.

4 **تدريب TF-IDF:** ملائمة مُمثّل `TfidfVectorizer` من `scikit-learn` على المتن المعالج وحفظ المصفوفة المتفرّقة

والمُثمّل.

5 **تدريب SBERT:** ترميز الوثائق بنموذج `all-MiniLM-L6-v2` (384 بُعداً) وبناء فهرس **FAISS** للبحث الكثيف السريع.

6 **تدريب Word2Vec:** تدريب نموذج خاص بالمتن (`gensim`) وحساب أشعة الوثائق بأخذ متوسط أشعة الكلمات.

7 **إعداد BM25:** تثبيت معاملات BM25 ($k1=1.5, b=0.75$) والتحقق من الفهرس وكتابة تقرير حساسية المعاملات.

8 **التحقق من الهجين (Verify Hybrid):** اختبار دُخان للتمثيل الهجين بنمطيه المتوازي والتسلسلي.

9 **التحميل إلى MongoDB:** تحميل الوثائق الأصلية (العنوان والنص) إلى قاعدة البيانات لعرض النتائج.

10 **التجميع (Clustering):** تجميع الوثائق إلى 20 عنقوداً بالاعتماد على أشعة SBERT وحفظ ملخصات العناقيد والإسقاط

ثنائي الأبعاد.

5. الخدمات بالتفصيل (Services)

5.1 خدمة المعالجة المسبقة (Preprocessing Service)

تتولى الصنف `TextPreprocessor` توحيد معالجة الوثائق والاستعلامات بنفس التقنيات لضمان التوافق. اعتمدت مكتبة **NLTK** حصراً. خطوات المعالجة بالترتيب:

1. تطبيق Unicode إلى ASCII (`NFKD`).
2. تحويل الأحرف إلى صغيرة (lowercase).
3. إزالة الروابط (URLs) ووسوم HTML والأرقام وعلامات الترقيم.
4. توحيد الفراغات.
5. التجزئة (Tokenization) عبر `word_tokenize`.
6. إزالة كلمات الوقف الإنكليزية (Stopwords) والرموز القصيرة (أقل من حرفين).
7. التجذير (Stemming) عبر **Porter Stemmer**.

اعتمد التجذير (**Stemming**) عبر Porter بدل الـ Lemmatization (المتاح لكنه معطل) لكونه أسرع وأكثر ملاءمة لحجم المتن. ينتج عن المعالجة تمثيلان: `processed_str` (نص للـ TF-IDF) و `processed_tokens` (قائمة كلمات للـ BM25 و Word2Vec والفهرس المقلوب).

5.2 خدمة الفهرسة (Indexing Service)

يبني الصنف `InvertedIndexManager` فهرساً مقلوباً بالشكل `{term → {doc_id: tf}}` ، ويخزن أطوال الوثائق وعددها (N) ومتوسط الطول (avg_dl) وتردد الوثيقة (df). يوفّر الفهرس حساب الـ IDF وفق صيغة BM25 المعيارية:

$$\text{idf}(t) = \log((N - df + 0.5) / (df + 0.5) + 1)$$

هذا الفهرس هو حجر الأساس لاسترجاع BM25 السريع، إذ يتيح الوصول الفوري إلى قوائم الإحالة (Postings).

5.3 خدمة الاسترجاع والتمثيل (Retrieval & Representation Service)

تدعم الخدمة خمس طرائق تمثيل/استرجاع، إضافةً إلى التمثيل الهجين:

الطريقة	المدخل	التمثيل	مقياس التشابه	أهم المعاملات
TF-IDF (VSM)	نص معالج	مصفوفة متفرقة (sklearn)	تشابه جيب التمام (Cosine)	sublinear_tf, max_df=0.85, min_df=3, max_features=150K
BM25	كلمات معالجة	فهرس مقلوب	دالة ترجيح BM25	k1=1.5, b=0.75 (قابلة للتعديل من الواجهة)
SBERT	نص أصلي	أشعة كثيفة 384 بُعد + FAISS	الجداء الداخلي = Cosine	HNSW فهرس, all-MiniLM-L6-v2
Word2Vec	كلمات معالجة	متوسط أشعة الكلمات (200 بُعد)	Cosine	vector_size=200, window=5, epochs=5
Hybrid	الاثنان	دمج متفرق + كثيف	دمج درجات / إعادة ترتيب	$\alpha=0.5$, fusion=min-max

التمثيل الهجين (Hybrid Representation)

- **المتوازي (Parallel):** يُنفذ الفرعان (المتفرق TF-IDF/BM25 والكثيف SBERT/Word2Vec) معاً، ثم تُدمج النتائج بطريقة **Min-Max Normalization** + المجموع الموزون:

$$\text{score} = \alpha \cdot \text{sparse_norm} + (1 - \alpha) \cdot \text{dense_norm}$$

مع توفر طريقة دمج بديلة **RRF (Reciprocal Rank Fusion, k=60)** في الكود. هذا يحقق متطلب "طرق دمج النتائج (Fusion Methods)" للنمط المتوازي.

- **التسلسلي (Serial / Cascade):** مرحلة أولى متفرقة (BM25) تُرشح أفضل N مرشح (افتراضياً 200)، ثم تُعيد المرحلة الكثيفة (SBERT) ترتيبها (Re-ranking).

توفر الواجهة للمستخدم التحكم بمعاملات النموذج الاحتمالي (BM25 (k1, b) ووزن الدمج α واختيار مكوّن الفرع المتفرق والكثيف للتمثيل الهجين، تحقيقاً لمتطلبات الواجهة والشفافية.

5.4 خدمة تحسين الاستعلام (Query Refinement Service)

- **التصحيح الإملائي:** عبر `pyspellchecker` مع حماية كلمات الوقف من التعديل.
 - **التوسيع بالمرادفات:** عبر **WordNet** من NLTK مع ترشيح المجالات الدلالية المناسبة.
 - **سجل البحث والاقتراحات:** حفظ آخر الاستعلامات في `search_history.json` وتقديم اقتراحات إكمال تلقائي بمطابقة البادئة.
- يُفعّل التحسين عند اختيار "النمط المُحسّن (Enhanced)"، مقابل "النمط الأساسي (Basic)" الذي يكتفي بالمعالجة القياسية.

5.5 خدمة الترتيب والتقييم (Ranking & Evaluation Service)

تُقيّم الخدمة جميع النماذج على استعلامات الاختبار مقابل ملف `qrels` وتحسب المقاييس المعيارية وتحفظها في `data/evaluation/`. تتكوّن من: `scorer.py` (حساب المقاييس)، و `evaluator.py` (تشغيل النماذج وبناء النتائج)، و `main.py` (واجهة سطر أوامر). المقاييس المحسوبة: **MAP, Recall, Precision@10, nDCG**.

5.6 بوابة ال API وواجهة المستخدم

تعرض البوابة (FastAPI) أهم النهايات (Endpoints):

الوظيفة	المسار	الطريقة
حالة البوابة وقاعدة البيانات	/health	GET
قائمة المجموعات وجاهزية النماذج	/api/v1/datasets	GET
تنفيذ خط البحث الكامل	/api/v1/search	POST
اقتراحات الإكمال التلقائي	/api/v1/suggestions	GET
قراءة نتائج التقييم	/api/v1/evaluation	GET
ملخصات العناقيد والإسقاط ثنائي الأبعاد	/api/v1/clusters	GET

أما واجهة المستخدم فمبنية بـ **React 19 + TypeScript + Vite**، وتتيح: اختيار نموذج الاسترجاع، التحكّم بمعاملات BM25 ووزن الدمج α ، التبديل بين النمط الأساسي والمُحسّن، عرض النتائج المرتّبة مع الدرجات، الاقتراحات أثناء الكتابة، وعرض الاستعلام بعد المعالجة (شفافية المعالجة).

6. التقييم والنتائج والتحليل

أُجري التقييم على 49 استعلاماً من مجموعة Webis-Touché 2020 بقيمة $\text{top_k} = 1000$ ، في الطور الأساسي (baseline). الجدول التالي يلخص النتائج التجميعية لكل نموذج (القيم الأعلى أفضل، والخلية الخضراء تشير إلى أفضل نموذج في كل مقياس):


النموذج	MAP	Recall@1000	P@10	nDCG@10	P@5	nDCG@100	الزمن (ث)
TF-IDF	0.0520	0.7330	0.0673	0.0566	0.0816	0.1420	5.72
BM25	0.2194	0.8726	0.2898	0.3172	0.3469	0.4414	11.78
SBERT	0.1312	0.7706	0.1673	0.1709	0.1796	0.2919	6.27
Word2Vec	0.1017	0.7441	0.1347	0.1561	0.1633	0.2533	2.06
Hybrid (Parallel)	0.2139	0.8784	0.2653	0.2908	0.3061	0.4228	9.99
Hybrid (Serial)	0.1431	0.8708	0.1755	0.1781	0.1796	0.3113	42.84

مقارنة بصرية

MAP (متوسط الدقة الوسطية)



nDCG@10



Recall@1000



تحليل النتائج

- **BM25 هو الأفضل إجمالاً** في MAP و P@10 و nDCG، ما يؤكّد قوّة الطرائق اللمنية (lexical) على هذه المجموعة الجدلية التي تعتمد كثيراً على تطابق المصطلحات.
- **التمثيل الهجين المتوازي** يحقق أعلى **Recall@1000** ويقترب جداً من BM25 في بقية المقاييس، لأنه يجمع قوّة BM25 اللمنية مع التغطية الدلالية لـ SBERT — وهو ما يحقق الفائدة المرجوة من الدمج.
- **SBERT و Word2Vec** (الكثيفة) أضعف من BM25 هنا، إذ تميل المجموعة للاعتماد على الكلمات المفتاحية أكثر من الدلالة العميقة، لكنها تساهم في رفع Recall ضمن الهجين.
- **TF-IDF** هو الأضعف، إذ يفتقر إلى تطبيع طول الوثيقة الذي يوفّره BM25 (المعامل b).
- **الهجين التسلسلي** أبطأ بكثير (42.8 ث) لأن مرحلة إعادة الترتيب الكثيفة مكلفة، دون أن يتفوّق على المتوازي.

الخلاصة التقييمية: أفضل توازن بين الجودة والتغطية هو **الهجين المتوازي (BM25 + SBERT, $\alpha=0.5$)**، بينما **BM25** هو الخيار الأمثل عند الحاجة إلى دقّة عالية وسرعة معقولة. النتائج منطقية ومتوافقة مع طبيعة مجموعة Touché الجدلية.

7. الميزة الإضافية: تجميع الوثائق (Documents Clustering)

الميزة الإضافية المحققة هي تجميع الوثائق غير المُوجَّه (Unsupervised Clustering)، بهدف تنظيم المتن في عناقيد موضوعية متجانسة تساعد على استكشاف المجموعة وتفسير نتائج البحث.

المنهجية

1. الاعتماد على أشعة SBERT الكثيفة (384 بُعداً) لأنها أغنى دلاليّاً وتنتج عناقيد موضوعية مترابطة أكثر من Word2Vec.
2. تطبيق خوارزمية MiniBatchKMeans (بدل KMeans العادي) لكفاءتها على البيانات الكبيرة (382 ألف وثيقة) من حيث الذاكرة والسرعة، بعدد عناقيد $k = 20$.
3. لكل عنقود: اختيار 3 وثائق ممثلة (الأقرب إلى المركز) واستخراج أهم 10 مصطلحات مميزة (تردد داخل العنقود مرجحاً بمدى انتشاره عبر بقية العناقيد).
4. إسقاط عيّنة طبقية (~10 آلاف وثيقة) إلى بُعدين عبر UMAP (مع PCA كبديل) لإنتاج رسم انتشار بصري.

الخاصية	القيمة
عدد العناقيد	20
مصدر التمثيل	SBERT (384 بُعد)
عدد الوثائق المُجمّعة	382,545
الخوارزمية	MiniBatchKMeans (batch=4096, n_init=5)
الإسقاط البصري	UMAP / PCA إلى بُعدين

أمثلة على العناقيد المكتشفة

العنقود	الحجم	النسبة	أبرز المصطلحات (مُجَدّرة)	الموضوع
0	25,151	6.57%	school, student, educ, children	التعليم
1	26,304	6.88%	god, christian, bibl, believ	الدين
7	21,080	5.51%	abort, life, right, human, kill	الإجهاض / الأخلاق
9	21,666	5.66%	god, exist, argument, debat	الجدل الفلسفي

تُظهر المصطلحات بصيغتها المُجَدّرة (مثل educ ← education، بعد التجذير في خطوة المعالجة المسبقة).

تُحفظ نتائج التجميع في clusters.json (ملخّصات)، و doc_cluster_map.pkl (إسناد كل وثيقة إلى عنقود)، و scatter_2d.json (نقاط الرسم). يمكن للبوابة تعليم نتائج البحث برقم العنقود عبر النهايات /api/v1/clusters و /api/v1/clusters/scatter.

8. تقسيم العمل بين أعضاء المجموعة

وُزّعت مهام المشروع على أعضاء المجموعة الأربعة بحسب مكّونات النظام كما يلي:

المهام الموكّلة	العضو
خدمة المعالجة المسبقة (تنظيف، تطبيع، تجذير) + بناء الفهرس المقلوب + تمثيل TF-IDF.	مجد جميل لوقا
التمثيلات الشعاعية الكثيفة (SBERT مع FAISS، Word2Vec) + التمثيل الهجين (متوازي/تسلسلي وطرق الدمج).	مجد سامر عروس
تمثيل BM25 + خدمة تحسين الاستعلام (تصحيح، مرادفات، سجل) + خدمة الترتيب والتقييم (المقاييس).	مصطفى عبد الناصر شرف
الميزة الإضافية (التجميع/Clustering) + بوابة الـ API وبنية SOA + واجهة المستخدم (React) + قاعدة .MongoDB.	محمد رياض عمر

شارك جميع الأعضاء في التكامل بين الخدمات، وكتابة الاختبارات، وإعداد التقرير، وضبط الأداء النهائي.

9. التقنيات المستخدمة والمصادر

التقنيات والمكتبات

المجال	الأدوات
اللغة	Python 3
الخادم والبوابة	FastAPI + Uvicorn
المعالجة اللغوية	NLTK (Tokenization, Stopwords, Porter Stemmer, WordNet)
التمثيل الكلمي	scikit-learn (TfidfVectorizer), فهرس مقلوب مخصّص (BM25)
التمثيل الكثيف	Sentence-Transformers (all-MiniLM-L6-v2), FAISS, gensim (Word2Vec)
تحسين الاستعلام	pyspellchecker, WordNet
التجميع والتمثيل البصري	scikit-learn (MiniBatchKMeans, PCA), UMAP
قاعدة البيانات	MongoDB (PyMongo) + Docker
الواجهة	React 19, TypeScript, Vite, Tailwind, TanStack Query, Zustand
البيانات	ir_datasets (BEIR / Webis-Touché 2020)

المصادر

- <https://ir-datasets.com>: BEIR Benchmark — Webis-Touché 2020 Dataset
- .Robertson & Zaragoza — *The Probabilistic Relevance Framework: BM25 and Beyond*
- .Reimers & Gurevych — *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*
- .Mikolov et al. — *Efficient Estimation of Word Representations in Vector Space (Word2Vec)*
- .Manning, Raghavan & Schütze — *Introduction to Information Retrieval*
- .McInnes, Healy & Melville — *UMAP: Uniform Manifold Approximation and Projection*

10. الخلاصة والأعمال المستقبلية

قدّم هذا المشروع نظام استرجاع معلومات متكاملًا مبنياً وفق البنية الموجهة بالخدمات (SOA)، يطبّق مراحل استرجاع المعلومات الأساسية كاملةً: المعالجة المسبقة، التمثيل بأربع طرائق (TF-IDF، BM25، SBERT، Word2Vec) مع تمثيل هجين متوازي وتسلسلي، والفهرسة المقلوبة، وتحسين الاستعلام، والترتيب والتقييم، إضافةً إلى واجهة مستخدم حديثة وميزة إضافية للتجميع. أظهر التقييم على مجموعة Webis-Touché 2020 تفوّق **BM25** في الدقّة، وتميّز **الهجين المتوازي** في التغطية (Recall)، بما يتوافق مع طبيعة المجموعة الجدلية. حقّق التصميم فصلاً واضحاً للمسؤوليات وقابلية للصيانة والتوسّع.

أعمال مستقبلية مقترحة

- ربط واجهة عرض التقييم ورسم العناقيد البصري بالواجهة الأمامية بشكل كامل.
- تشغيل طور التقييم المُحسّن (Enhanced) لقياس أثر تحسين الاستعلام كمياً (قبل/بعد).
- تجربة دمج RRF كخيار افتراضي ومقارنته بالمجموع الموزون.
- إضافة دعم الاسترجاع المعزّز بالتوليد (RAG) ومخازن الأشعة (Vector Stores).

— انتهى التقرير —

مادة استرجاع المعلومات 2026 — بإشراف م. مروة الداية